

# Inferencia Estadística

Marisol García Peña

Departamento de Matemáticas  
Pontificia Universidad Javeriana

Bogotá, 2022

## Ejemplo

Sea  $X_1, \dots, X_n$  una m.a. de alguna distribución tal que  $E[X_i] = \mu$  y  $V[X_i] = \sigma^2$ ,  $i = 1, \dots, n$ . Considere los estimadores de  $\mu$ ,  $T_1 = \bar{X}$  y  $T_2 = \sum_{i=1}^n \frac{X_i}{n+1}$ .

Obtener los ECM de  $T_1$  y  $T_2$  y demuestre que  $ECM[T_2] < ECM[T_1]$  para algunos valores de  $\mu$  mientras que la proposición inversa es cierta para otros valores de  $\mu$ .

## Insesgadez/Insesgamiento

Un estimador  $T(X_1, \dots, X_n)$  es definido como estimador insesgado de  $\tau(\theta)$  si y sólo si

$$E_{\theta}[\hat{\theta}] = E_{\theta}[T(X_1, \dots, X_n)] = \tau(\theta)$$

Un estimador es insesgado si su valor esperado es igual a  $\tau(\theta)$ .

## Ejemplo

Sea  $X_1, \dots, X_n$  una m.a. de una distribución  $N(\mu, \sigma^2)$ .

- Muestre que  $\bar{X} = \sum_{i=1}^n \frac{X_i}{n}$  es un estimador insesgado de  $\mu$ .
- Muestre que  $S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$  es un estimador insesgado de  $\sigma^2$ .
- Muestre que  $\hat{\sigma}^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}$  es un estimador sesgado de  $\sigma^2$ .

## Ejemplo

Sea  $X_1, \dots, X_n$  una m.a. i.i.d  $U(0, \beta)$ . El EMV de  $\beta$  es  $\hat{\beta}_{MV} = X_{(n)} = \text{máx.}$   
 $\hat{\beta}$  es un estimador insesgado?

La f.d.p de  $\hat{\beta}$  es  $f_{\text{máx}}(x) = \frac{n}{\beta^n} x^{n-1}$ . Su valor esperado es

$$E[\hat{\beta}] = E[X_{(n)}] = \int_0^{\beta} x \frac{n}{\beta^n} x^{n-1} dx = \frac{n}{n+1} \beta$$

Entonces  $\hat{\beta}_{MV} = X_{(n)}$  es un estimador sesgado de  $\beta$ . Pero  $\frac{n+1}{n} X_{(n)}$  es insesgado.

Si se usa el estimador del método de momentos  $\hat{\beta} = 2\bar{X}$ . Su valor esperado es  $E[\hat{\beta}] = E[2\bar{X}] = 2\frac{\beta}{2} = \beta$ . Esto indica que el estimador de  $\beta$  por el método de momentos es insesgado.

- Si  $T(X_1, \dots, X_n)$  es un estimador insesgado para  $\tau(\theta) \implies h(T)$  en general no es un estimador insesgado de  $h(\tau(\theta))$ .
- El estimador insesgado que minimiza el ECM se conoce como **MVUE- Minimum Variance Unbiased Estimator** de  $\tau(\theta)$ .

## Estimador asintóticamente insesgado

Sea  $X_1, \dots, X_n$  una m.a. con función de densidad, y sea  $T(X_1, \dots, X_n)$  un estimador puntual de  $\tau(\theta)$ . Se dice que  $T$  es un estimador asintóticamente insesgado si

$$\lim_{n \rightarrow \infty} E[T(X_1, \dots, X_n)] = \tau(\theta)$$



## Ejemplo

En el caso del estimador de  $\beta$ ,  $X_{(n)}$

$$\lim_{n \rightarrow \infty} E[X_{(n)}] = \lim_{n \rightarrow \infty} \frac{n}{n+1} \beta = \beta.$$

Para el estimador de  $\sigma^2$  de una  $N(\mu, \sigma^2)$ , se tiene

$$\lim_{n \rightarrow \infty} E[\hat{\sigma}^2] = \lim_{n \rightarrow \infty} \frac{n-1}{n} \sigma^2 = \sigma^2.$$

Estos estimadores son asintóticamente insesgados.

Si se tienen 2 estimadores insesgados de  $\tau(\theta)$ . ¿Cuál se debe seleccionar?

### Eficiencia

Sean  $T_1(X_1, \dots, X_n)$  y  $T_2(X_1, \dots, X_n)$  dos estimadores insesgados de  $\tau(\theta)$ . Se dice que  $T_1$  es **más eficiente** que  $T_2$  si se verifica que

$$V[T_1(X_1, \dots, X_n)] < V[T_2(X_1, \dots, X_n)]$$

Es decir, un estimador más eficiente que otro tiene menor varian-za/dispersión.

## Eficiencia relativa

Sean  $T_1(X_1, \dots, X_n)$  y  $T_2(X_1, \dots, X_n)$  dos estimadores insesgados de  $\tau(\theta)$ . Se define la **eficiencia relativa de  $T_1$  respecto a  $T_2$**  como

$$E.R.[T_1, T_2] = \frac{V[T_2]}{V[T_1]}$$

Si  $E.R.[T_1, T_2] > 1 \implies T_1$  es más eficiente que  $T_2$ , caso contrario  $T_2$  será más eficiente que  $T_1$ .

## Ejemplo


Sean  $X_1, \dots, X_{n_1}$  y  $Y_1, \dots, Y_{n_2}$  dos muestras aleatorias independientes de una población  $N(\mu, \sigma^2)$  con medias  $\bar{X}_1$  y  $\bar{X}_2$  respectivamente.

Un investigador pretende estimar la media poblacional  $\mu$  y propone 2 estimadores alternativos


$$\hat{\mu} = \frac{1}{2}(\bar{X}_1 + \bar{X}_2) \quad \text{y} \quad \tilde{\mu} = \frac{n_1 \bar{X}_1 + n_2 \bar{X}_2}{n_1 + n_2}$$

¿Cuál de esos estimadores es más adecuado para estimar  $\mu$ ?


# Estimación puntual (cont.)



Insesgado



Eficiente



Insesgado y Eficiente

## Consistencia y BAN

- *ECM* y la propiedad de insesgamiento  $\implies n$  fijo.
- 2 conceptos  $\implies$  aumento de  $n$ .
- Notación,  $T(X_1, \dots, X_n) \implies T_n(X_1, \dots, X_n)$ .
- Secuencia de estimadores,  $T_1(X_1), T_2(X_1, X_2), \dots, T_n(X_1, \dots, X_n)$ .
- Buena secuencia de estimadores  $\implies$  Los valores de los estimadores  $\implies$  acerca a la cantidad estimada cuando  $n \uparrow$

## Consistencia de error cuadrático medio

Sea  $T_1, T_2, \dots, T_n$  una secuencia de estimadores de  $\tau(\theta)$ , donde  $T_n(X_1, \dots, X_n)$  está basado en una muestra de tamaño  $n$ .

La secuencia de estimadores se define como secuencia de estimadores de  $\tau(\theta)$  *consistente de error cuadrático medio*, si y sólo si

$$\lim_{n \rightarrow \infty} E[[T_n - \tau(\theta)]^2] = 0, \forall \theta$$

Consistencia de error cuadrático medio  $\implies$  sesgo y varianza de  $T_n$  se aproximan a 0 ya que  $E[[T_n - \tau(\theta)]^2] = V[T_n] + \{\tau(\theta) - E[T_n]\}^2$ .

## Ejemplo

En un muestreo de una densidad con media  $\mu$  y varianza  $\sigma^2$ , sea  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  una secuencia de estimadores de  $\mu$  y  $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  una secuencia de estimadores de  $\sigma^2$ .

$E[(\bar{X}_n - \mu)^2] = V[\bar{X}] = \frac{\sigma^2}{n} \rightarrow 0$  cuando  $n \rightarrow \infty$ ; en este caso, la secuencia  $\{\bar{X}_n\}$  es una secuencia de estimadores de  $\mu$  consistente de ECM.

$E[(S_n^2 - \sigma^2)^2] = V[S_n^2] = \frac{1}{n} (\mu_4 - \frac{n-3}{n-1} \sigma^4) \rightarrow 0$  cuando  $n \rightarrow \infty$ , la secuencia  $\{S_n^2\}$  es una secuencia de estimadores de  $\sigma^2$  consistente de ECM.

Si  $T_n = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ , la secuencia  $\{T_n\}$  también es una secuencia de estimadores de  $\sigma^2$  consistente de ECM.



## Consistencia simple

Sea  $T_1, \dots, T_n$  una secuencia de estimadores de  $\tau(\theta)$ , donde  $T_n(X_1, \dots, X_n)$ . La secuencia  $\{T_n\}$  es definida como una secuencia de estimadores de  $\tau(\theta)$  *consistente simple (débil)* si para cada  $\varepsilon > 0$  se satisface:

$$\lim_{n \rightarrow \infty} P[|T_n - \tau(\theta)| \leq \varepsilon] = 1; \forall \theta, \forall \varepsilon > 0$$

o equivalentemente,

$$\lim_{n \rightarrow \infty} P[|T_n - \tau(\theta)| > \varepsilon] = 0; \forall \theta, \forall \varepsilon > 0$$

Convergencia en probabilidad.

Para una cantidad aceptable de error  $\varepsilon > 0$ , la probabilidad de que el error real empeore más que  $\varepsilon$  tiende a cero.

- La consistencia de un estimador garantiza que si se tiene un tamaño de muestra grande cualquier estimación particular va a estar cerca del valor de  $\tau(\theta)$ .
- Si un estimador es un estimador consistente de ECM también es un estimador consistente simple, lo contrario no necesariamente es cierto.

## Ejemplo

Sea  $X_1, \dots, X_n$  denota una muestra aleatoria de  $N(\mu, 1)$  y sea  $\bar{X}_n$  la media muestral. Muestre que  $\bar{X}_n$  es un estimador consistente para  $\mu$ .

## Ejemplo

Sea  $X_1, \dots, X_n$  denota una muestra aleatoria de una distribución Bernoulli  $(1, \theta)$ . Muestre que  $\bar{X}$  es un estimador consistente para  $\theta$ ,  $0 < \theta < 1$ .

## Ejemplo

Sea  $X_1, \dots, X_n$  denota una muestra aleatoria de  $N(\mu, \sigma^2)$  y sea  $S_n^2$  la varianza muestral. Muestre que  $S_n^2$  es un estimador consistente para  $\sigma^2$ .

## Consistencia

Sea  $X_1, \dots, X_n$  una muestra aleatoria de una f.d.p. Sea  $\{T_n\}$  una secuencia de estimadores de  $\tau(\theta)$ , tal que

$$\lim_{n \rightarrow \infty} E[T(X_1, \dots, X_n)] = \tau(\theta)$$

$$\lim_{n \rightarrow \infty} V[T(X_1, \dots, X_n)] = 0$$

Entonces  $T_n$  es consistente para  $\tau(\theta)$ .

## Recordando

Por el TCL. Sea  $\{X_n\}$  una secuencia de v.a's iid con  $E[X_i] = \mu$  y  $V[X_i] = \sigma^2$ ,  $0 < \sigma^2 < \infty$  entonces

$$\frac{T_n - E[T_n]}{S_n} \xrightarrow[n \rightarrow \infty]{D} N(0, 1)$$

donde  $T_n = \sum_{i=1}^n X_i$ ,  $S_n^2 = V[T_n]$

$$E[T_n] = E\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n E[X_i] = n\mu$$

$$V[T_n] = V\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n V[X_i] = n\sigma^2$$

De lo anterior, tenemos que

$$\begin{aligned}\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} &= \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \\ \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} &\xrightarrow[n \rightarrow \infty]{D} N(0, 1) \\ \sqrt{n}(\bar{X} - \mu) &\xrightarrow[n \rightarrow \infty]{D} N(0, \sigma^2)\end{aligned}$$



## Ejemplo

Sean  $X_1, \dots, X_n$  v.a's iid tales que  $X \sim U(0, \theta)$ ,  $\theta > 0$ . Demuestre que  $\sqrt{n}(\bar{X} - \frac{\theta}{2}) \xrightarrow[n \rightarrow \infty]{D} N(0, \theta^2/12)$ , donde  $\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$ .

$$E[X] = \frac{\theta}{2} \quad E[X^2] = \frac{\theta^2}{3} \quad V[X] = E[X^2] - (E[X])^2 = \frac{\theta^2}{3} - \frac{\theta^2}{4} = \frac{\theta^2}{12}$$

Por TCL, se tiene

$$\sqrt{n}(\bar{X} - \theta/2) \xrightarrow[n \rightarrow \infty]{D} N(0, \theta^2/12)$$

## Método Delta

Sea  $\{T_n\}$  una secuencia de v.a's,  $\mu \in \mathbb{R}$  y  $g$  una función real de variable real, derivable en un intervalo que contiene el punto  $\mu$ , con  $g'(\mu) \neq 0$ .

Se  $\sqrt{n}(T_n - \mu) \xrightarrow[n \rightarrow \infty]{D} N(0, \sigma^2)$ , entonces

$$\sqrt{n}(g(T_n) - g(\mu)) \xrightarrow[n \rightarrow \infty]{D} N(0, (g'(\mu))^2 \sigma^2)$$

## Ejemplo

Sea  $X_1, \dots, X_n$  iid con  $E[X] = \mu$  y  $V[X] = \sigma^2 < \infty$ . Muestre que

①  $\sqrt{n}(\bar{X}^2 - \mu^2) \xrightarrow[n \rightarrow \infty]{D} N(0, 4\sigma^2\mu^2).$

②  $\sqrt{n}\left(\frac{1}{\bar{X}} - \frac{1}{\mu}\right) \xrightarrow[n \rightarrow \infty]{D} N\left(0, \frac{\sigma^2}{\mu^4}\right)$

## Mejores estimadores asintóticamente normales - BAN (best asymptotically normal estimators)

Una secuencia de estimadores  $T_1^*, \dots, T_n^*$  de  $\tau(\theta)$  se define como el mejor asintóticamente normal (BAN) si y solo si se satisfacen las siguientes 4 condiciones:

- 1 La distribución de  $\sqrt{n}[T_n^* - \tau(\theta)] \xrightarrow[n \rightarrow \infty]{D} N(0, \sigma^{*2}(\theta))$ .
- 2 Para cada  $\varepsilon > 0$ ,  $\lim_{n \rightarrow \infty} P[|T_n^* - \tau(\theta)| > \varepsilon] = 0$ .
- 3 Sea  $\{T_n\}$  una secuencia de estimadores consistente simple para la cual la distribución de  $\sqrt{n}[T_n - \tau(\theta)] \xrightarrow[n \rightarrow \infty]{D} N(0, \sigma^2(\theta))$ .
- 4  $\sigma^2(\theta)$  no es menor que  $\sigma^{*2}(\theta) \forall \theta$  en un intervalo abierto.

- BAN a veces se reemplaza por CANE - Consistent asymptotically normal efficient.
- Estimadores BAN  $\implies$  son consistentes por (2).

## Consistencia y normalidad asintótica para EMV

Sea  $X_1, \dots, X_n$  una muestra aleatoria de tamaño  $n$  de una función de densidad o de probabilidad  $f(x; \theta)$  que satisface ciertas condiciones de regularidad y sea  $\hat{\Theta}_n$  el estimador de máxima verosimilitud de  $\theta$ , entonces:

1  $\hat{\Theta}_n \xrightarrow[n \rightarrow \infty]{D} N \left( \theta, \frac{1}{nE \left\{ \left[ \frac{\partial}{\partial \theta} \log f(X; \theta) \right]^2 \right\}} \right).$

2 La secuencia de estimadores de máxima verosimilitud  $\hat{\Theta}_1, \dots, \hat{\Theta}_n$  es BAN y por tanto consistente.

3  $\sqrt{n}(\hat{\Theta}_n - \theta) \xrightarrow[n \rightarrow \infty]{D} N \left( 0, \frac{1}{E \left\{ \left[ \frac{\partial}{\partial \theta} \log f(X; \theta) \right]^2 \right\}} \right).$

## Ejemplo

Sea  $X_1, \dots, X_n$  una muestra aleatoria de una distribución exponencial negativa  $f(x; \theta) = \theta e^{-\theta x} I_{[0, \infty)}(x)$ . El estimador de máxima verosimilitud de  $\theta$  es  $\frac{1}{\bar{X}_n}$ .

De acuerdo al teorema anterior,

$$\frac{1}{\bar{X}_n} \xrightarrow[n \rightarrow \infty]{D} N \left( \theta, \frac{1}{nE \left\{ \left[ \frac{\partial}{\partial \theta} \log f(X; \theta) \right]^2 \right\}} = \frac{\theta^2}{n} \right)$$

## Estimación puntual (cont.)

- Se ha considerado la estimación de  $\tau(\theta)$ , una función de  $\theta$  y no la estimación simplemente de  $\theta$ .
- La EMV de  $\tau(\theta)$  está dada por  $\tau(\hat{\Theta})$ , donde  $\hat{\Theta}$  es el EMV de  $\theta$ .
- Si  $\tau(\bullet)$  es diferenciable, entonces

$$\tau(\hat{\Theta}) \xrightarrow[n \rightarrow \infty]{D} N \left( \tau(\theta), \frac{[\tau'(\theta)]^2}{nE \left\{ \left[ \frac{\partial}{\partial \theta} \log f(X; \theta) \right]^2 \right\}} \right)$$

La varianza de la última expresión se conoce como Cota inferior de Cramér-Rao.



## Información de Fisher - $I_F(\theta)$

Sea  $X$  una v.a. con función de densidad o de probabilidad  $f(x; \theta)$ . La información de Fisher o llamada información total de Fisher de una v.a.  $X$  está dada por

$$I_F(\theta) = E \left\{ \left[ \frac{\partial}{\partial \theta} \log f(X; \theta) \right]^2 \right\}$$

Se existe  $\frac{\partial^2}{\partial \theta^2} \log f(X; \theta)$ ,  $\forall \theta$ , entonces

$$I_F(\theta) = -E \left[ \frac{\partial^2}{\partial \theta^2} \log f(X; \theta) \right]$$

# Estimación puntual (cont.)

## Ejemplo

Sea  $X$  una v.a. con distribución Bernoulli  $(1, \theta)$ . Encuentre la información de Fisher de la v.a.  $X$ .  $P[X = x] = \theta^x(1 - \theta)^{1-x}$ ;  $x = 0, 1$ .

$$\log P[X = x] = x \log(\theta) + (1 - x) \log(1 - \theta)$$

$$\frac{\partial}{\partial \theta} \log P[X = x] = \frac{x}{\theta} - \frac{(1 - x)}{1 - \theta}$$

$$\frac{\partial^2}{\partial \theta^2} \log P[X = x] = -\frac{x}{\theta^2} - \frac{(1 - x)}{(1 - \theta)^2}$$

$$\begin{aligned} -E \left[ \frac{\partial^2}{\partial \theta^2} \log P[X = x] \right] &= -E \left[ -\frac{x}{\theta^2} - \frac{(1 - x)}{(1 - \theta)^2} \right] = E \left[ \frac{x}{\theta^2} \right] + E \left[ \frac{1 - x}{(1 - \theta)^2} \right] \\ &= \frac{E[x]}{\theta^2} + \frac{E[1 - x]}{(1 - \theta)^2} = \frac{\theta}{\theta^2} + \frac{1 - \theta}{(1 - \theta)^2} = \frac{1}{\theta} + \frac{1}{1 - \theta} \\ &= \frac{1}{\theta(1 - \theta)} \end{aligned}$$

## Ejemplo

Sea  $X$  una v.a. con distribución Poisson ( $\lambda$ ). Encuentre la información de Fisher de la v.a.  $X$ . Recuerde que  $P[X = x] = \frac{\lambda^x e^{-\lambda}}{x!}$ .