

# Inferencia Estadística

Marisol García Peña

Departamento de Matemáticas  
Pontificia Universidad Javeriana

Bogotá, 2022

## Ejemplo

Sea  $X_1, \dots, X_n$  una muestra aleatoria de una población geométrica con parámetro  $\pi$ . Muestre que  $\bar{X}$  es una estadística suficiente para  $\pi$ .  $P[X_i = x_i] = \pi(1 - \pi)^{x-1}, x_i \geq 1$

## Ejemplo

Sea  $X_1, \dots, X_n$  una muestra aleatoria de una población  $U(0, \theta)$ .  $f(x_i, \theta) = \frac{1}{\theta}, 0 < x < \theta, \theta > 0$ . Muestre que  $X_{(n)} = \max_{1 \leq i \leq n} X_i$  es una estadística suficiente para  $\theta$ .

## Teorema de la factorización para estadísticas conjuntamente suficientes

### Teorema

Sea  $X_1, \dots, X_n$  una muestra aleatoria de tamaño  $n$  de una densidad  $f(\bullet, \theta)$ , donde el parámetro  $\theta$  puede ser un vector. Un conjunto de estadísticas  $S_1(X_1, \dots, X_n), \dots, S_r(X_1, \dots, X_n)$  es conjuntamente suficiente si y sólo si la densidad conjunta de  $X_1, \dots, X_n$  puede ser factorizada como

$$\begin{aligned} f(x_1, \dots, x_n; \theta) &= g(s_1(x_1, \dots, x_n), \dots, s_r(x_1, \dots, x_n), \theta) h(x_1, \dots, x_n) \\ &= g(s_1, \dots, s_r, \theta) h(\mathbf{x}) \end{aligned}$$

donde la función  $h(x_1, \dots, x_n)$  es no negativa y no depende de  $\theta$  y la función  $g(s_1, \dots, s_r, \theta)$  es no negativa y depende de  $\theta$  y del valor de la estadísticas  $s_1, \dots, s_r$ .

## Ejemplo

Sea  $X_1, \dots, X_n$  una muestra aleatoria de una distribución  $N(\mu, \sigma^2)$  donde  $\mu$  y  $\sigma^2$  son desconocidos, encuentre las estadísticas suficientes para los parámetros.

$$\begin{aligned} f_{\mathbf{x}, \theta}(\mathbf{x}, \theta) &= \prod_{i=1}^n f(x_i, \theta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{1}{2} \frac{(x_i - \mu)^2}{\sigma^2} \right\} \\ &= \left( \frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} \\ &= \left( \frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} \left[ \sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2 \right] \right\} \\ &= \underbrace{\left( \frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left\{ -\frac{n\mu^2}{2\sigma^2} \right\}}_{g(\mathbf{s}, \theta)} \exp \left\{ \frac{\mu}{\sigma^2} \sum_{i=1}^n x_i - \frac{\sum_{i=1}^n x_i^2}{2\sigma^2} \right\} \underbrace{1}_{h(\mathbf{x})} \end{aligned}$$

$S(X) = (\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2)$  son est. conj. suficientes para  $\theta = (\mu, \sigma^2)$ .

## Teorema

*Un estimador de máxima verosimilitud o un conjunto de estimadores de máxima verosimilitud dependen de la muestra a través de cualquier conjunto de estadísticas conjuntamente suficientes.*

El máximo de  $L(x_1, \dots, x_n, \theta)$  se obtiene en el mismo punto que el máximo de  $g(s_1, \dots, s_r, \theta)$ .

## Teorema

*Si  $S$  es una estadística suficiente para  $\theta$  y si el EMV de  $\theta$  es único, entonces es una función de  $S$ .*

## Estadísticas suficientes minimales

- Una estadística  $S$  es suficiente minimal si no se puede reducir más sin violar la propiedad de suficiencia.
- La estadística  $\mathbf{S} = (S_1, \dots, S_m)$  es suficiente minimal si  $m$  es la menor dimensión de  $\mathbf{S}$  tal que  $\mathbf{S}$  continúe siendo suficiente para  $\theta$ .
- Si para un problema existe un único estimador de máxima verosimilitud  $\hat{\theta}$  para  $\theta$  y si  $\hat{\theta}$  es una estadística suficiente entonces  $\hat{\theta}$  es suficiente minimal.

Un conjunto de estadísticas conjuntamente suficientes es suficiente minimal si y sólo si es una función de cualquier otro conjunto de estadísticas suficientes.

### Teorema

Sea  $X_1, \dots, X_n$  una muestra aleatoria de una función de densidad o de probabilidad  $f(x, \theta)$ . Se dice que  $\mathbf{S}(\mathbf{X})$  es una estadística suficiente minimal si para cualquier par de puntos muestrales  $\mathbf{x}$  y  $\mathbf{y}$  se tiene que

$$\frac{f_{\mathbf{x}}(\mathbf{x}, \theta)}{f_{\mathbf{y}}(\mathbf{y}, \theta)} \text{ no depende de } \theta \Leftrightarrow \mathbf{S}(\mathbf{X}) = \mathbf{S}(\mathbf{Y})$$

# Estimación puntual (cont.)

## Ejemplo

Sea  $X_1, \dots, X_n$  una muestra aleatoria de una distribución  $N(\mu, \sigma^2)$  con  $\mu$  conocido. Encuentre una estadística suficiente minimal para  $\sigma^2 = \theta$ .

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x}, \theta) &= \left( \frac{1}{\sqrt{2\pi}} \sigma \right)^n \exp \left\{ \frac{-n\mu^2}{2\sigma^2} \right\} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 + \frac{\mu}{\sigma^2} \sum_{i=1}^n x_i \right\} \\ f_{\mathbf{Y}}(\mathbf{y}, \theta) &= \left( \frac{1}{\sqrt{2\pi}} \sigma \right)^n \exp \left\{ \frac{-n\mu^2}{2\sigma^2} \right\} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n y_i^2 + \frac{\mu}{\sigma^2} \sum_{i=1}^n y_i \right\} \\ \frac{f_{\mathbf{X}}(\mathbf{x}, \theta)}{f_{\mathbf{Y}}(\mathbf{y}, \theta)} &= \frac{\exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 + \frac{\mu}{\sigma^2} \sum_{i=1}^n x_i \right\}}{\exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n y_i^2 + \frac{\mu}{\sigma^2} \sum_{i=1}^n y_i \right\}} = \frac{\exp \left\{ -\frac{1}{2\sigma^2} [\sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i] \right\}}{\exp \left\{ -\frac{1}{2\sigma^2} [\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i] \right\}} \\ &= \exp \left\{ \frac{1}{2\sigma^2} \left[ \sum_{i=1}^n y_i^2 - \sum_{i=1}^n x_i^2 \right] + \frac{\mu}{\sigma^2} \left[ \sum_{i=1}^n x_i - \sum_{i=1}^n y_i \right] \right\} \end{aligned}$$

No depende de  $\sigma^2 \Leftrightarrow S_1(X) = \sum_{i=1}^n x_i = \sum_{i=1}^n y_i$  y  $S_2(X) = \sum_{i=1}^n x_i^2 = \sum_{i=1}^n y_i^2$ . Entonces  $\mathbf{S}(\mathbf{X}) = (S_1(\mathbf{X}), S_2(\mathbf{X}))$  es una estadística suficiente minimal para  $\sigma^2$ .



## Familia exponencial

Una familia de densidades de un parámetro ( $\theta$  unidimensional)  $f(x, \theta)$  que se puede expresar como

$$f(x, \theta) = c(\theta)h(x) \exp[Q(\theta)T(x)]$$

para  $-\infty < x < \infty$  para todo  $\theta$  y para una elección adecuada de funciones  $c(\bullet)$ ,  $h(\bullet)$ ,  $Q(\bullet)$  y  $T(\bullet)$ , pertenece a la *familia exponencial* o *clase exponencial*.

# Estimación puntual (cont.)

## Ejemplo

Sea  $f(x, \theta) = \theta e^{-\theta x} I_{(0, \infty)}(x)$ . ¿Pertenece a la familia exponencial?

Con  $c(\theta) = \theta$ ,  $h(x) = I_{(0, \infty)}(x)$ ,  $Q(\theta) = -\theta$ ,  $T(x) = x$ ,  $f(x, \theta)$  pertenece a la familia exponencial.

## Ejemplo

$f(x, \theta) = f(x, \lambda)$  es Poisson. ¿Pertenece a la familia exponencial?

$$\begin{aligned} P[X = x] &= \frac{e^{-\lambda} \lambda^x}{x!} I_{\{0, 1, \dots\}}(x) \\ &= e^{-\lambda} \left( \frac{1}{x!} I_{\{0, 1, \dots\}}(x) \right) \exp(x \log \lambda) \end{aligned}$$

$c(\lambda) = e^{-\lambda}$ ,  $h(x) = (1/x!) I_{\{0, 1, \dots\}}(x)$ ,  $Q(\lambda) = \log \lambda$  y  $T(x) = x$ , por tanto pertenece a la familia exponencial.

Si  $f(x, \theta) = c(\theta)h(x) \exp[Q(\theta)T(x)]$ , entonces

$$\prod_{i=1}^n f(x_i, \theta) = c^n(\theta) \left[ \prod_{i=1}^n h(x_i) \right] \exp \left[ Q(\theta) \sum_{i=1}^n T(x_i) \right]$$

por el criterio de factorización  $\sum_{i=1}^n T(X_i)$  es una estadística suficiente.

## Familia exponencial $k$ -paramétrica

Una familia de densidades  $f(\bullet, \theta_1, \dots, \theta_k)$  que puede ser expresada como

$$f(x, \theta_1, \dots, \theta_k) = c(\theta_1, \dots, \theta_k) h(x) \exp \left\{ \sum_{j=1}^k Q_j(\theta_1, \dots, \theta_k) T_j(x) \right\}$$

pertenece a la familia exponencial  $k$ -paramétrica.

## Ejemplo

Sea  $X \sim \text{Bin}(n, \theta)$ ,  $0 < \theta < 1$ . Muestre que la distribución pertenece a la familia exponencial.

$$\begin{aligned} P[X = x] &= \binom{n}{x} \theta^x (1 - \theta)^{n-x} I_{(0, \dots, n)}(x) \\ &= \binom{n}{x} \exp[\log(\theta^x)] \exp[\log(1 - \theta)^{n-x}] I_{(0, \dots, n)}(x) \\ &= \underbrace{\binom{n}{x} I_{(0, \dots, n)}(x)}_{h(x)} \underbrace{(1 - \theta)^n}_{c(\theta)} \exp[\underbrace{x}_{T_1(X)} \underbrace{\log(\theta / (1 - \theta))}_{Q_1(\theta)}] \end{aligned}$$

## Teorema

Sea  $f(x, \theta)$  una función de densidad o de probabilidad de la familia exponencial  $k$ -paramétrica

$$f(x, \theta) = c(\theta)h(x) \exp \left\{ \sum_{j=1}^k Q_j(\theta) T_j(x) \right\}$$

si se considera una muestra aleatoria de tamaño  $n$  de esa familia, se tiene que

$$P_j(X) = \sum_{i=1}^n T_j(X_i)$$

son conjuntamente suficientes para  $\theta$ .

## Ejemplo

En el ejemplo anterior de la Binomial,  $j = 1$  solo un parámetro  $\theta$ .

$$P_1(X) = \sum_{i=1}^n T_1(X_i) = \sum_{i=1}^n X_i$$

Entonces  $P_1(X) = \sum_{i=1}^n X_i$  es una estadística suficiente para  $\theta$

Si

$$f(x, \theta_1, \dots, \theta_k) = c^n(\theta_1, \dots, \theta_k) \left[ \prod_{i=1}^n h(x_i) \right] \exp \left[ \sum_{j=1}^k Q_j(\theta_1, \dots, \theta_k) \sum_{i=1}^n T_j(x_i) \right]$$

por el criterio de factorización  $\sum_{i=1}^n T_1(X_i), \dots, \sum_{i=1}^n T_k(X_i)$  es un conjunto de estadísticas suficientes y minimales.



## Estimación insesgada

- $ECM[T(\tau(\theta))] = E[(T - \tau(\theta))^2] = V[T] + \{\tau(\theta) - E[T]\}^2.$
- Si  $T$  es un estimador insesgado de  $\tau(\theta) \implies E[T] = \tau(\theta)$  y  $ECM[T(\tau(\theta))] = V[T].$
- Estimador de error cuadrático medio uniformemente mínimo entre los estimadores insesgados.
- Estimador con varianza uniformemente mínima entre los estimadores insesgados.

## Estimador insesgado de varianza uniformemente mínima - UMVUE

Sea  $X_1, \dots, X_n$  es una muestra aleatoria de  $f(\bullet, \theta)$ . Un estimador  $T^*(X_1, \dots, X_n)$  de  $\tau(\theta)$  es definido como un estimador insesgado de varianza uniformemente mínima de  $\tau(\theta)$  si y sólo si:

- 1  $E[T^*] = \tau(\theta) \implies$  estimador insesgado.
- 2  $V[T^*] \leq V[T]$  para cualquier otro estimador  $T(X_1, \dots, X_n)$  de  $\tau(\theta)$  que también es insesgado,  $E[T] = \tau(\theta)$ .

Uniformly minimum-variance unbiased estimator - UMVUE

## Límite inferior para varianza

Sea  $X_1, \dots, X_n$  es una variable aleatoria con función de densidad o probabilidad  $f(\bullet, \theta)$ . Sea  $T = (X_1, \dots, X_n)$  un estimador insesgado de  $\tau(\theta)$ .  $f(\bullet, \theta)$  satisface las siguientes *condiciones de regularidad* (caso continuo):

- i  $\frac{\partial}{\partial \theta} \log f(x, \theta)$  existe  $\forall x$  y  $\forall \theta$ .
- ii  $\frac{\partial}{\partial \theta} \int \cdots \int \prod_{i=1}^n f(x_i, \theta) dx_1 \cdots dx_n = \int \cdots \int \frac{\partial}{\partial \theta} \prod_{i=1}^n f(x_i, \theta) dx_1 \cdots dx_n$ .
- iii 
$$\begin{aligned} \frac{\partial}{\partial \theta} \int \cdots \int t(x_1, \dots, x_n) \prod_{i=1}^n f(x_i, \theta) dx_1 \cdots dx_n \\ = \int \cdots \int t(x_1, \dots, x_n) \frac{\partial}{\partial \theta} \prod_{i=1}^n f(x_i, \theta) dx_1 \cdots dx_n. \end{aligned}$$
- iv  $0 < E \left[ \left[ \frac{\partial}{\partial \theta} \log f(X, \theta) \right]^2 \right] < \infty, \forall \theta$ .

## Teorema

### Desigualdad de Cramér-Rao

*Bajo las condiciones (i) a (iv) se tiene*

$$V[T] \geq \frac{[\tau'(\theta)]^2}{nE \left[ \left[ \frac{\partial}{\partial \theta} \log f(X, \theta) \right]^2 \right]}$$

*donde  $T(X_1, \dots, X_n)$  es un estimador insesgado de  $\tau(\theta)$ . La igualdad se obtiene si y sólo si existe una función  $K(\theta, n)$  tal que*

$$\sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(X, \theta) = K(\theta, n)[t(x_1, \dots, x_n) - \tau(\theta)].$$

*La parte derecha se conoce como Cota inferior de Cramér-Rao para la varianza de estimadores insesgados de  $\tau(\theta)$ .*

## Estimación puntual (cont.)

- Proporciona una cota inferior para la varianza de estimadores insesgados.
- Si  $T(X)$  es un estimador insesgado de  $\tau(\theta)$  y si  $V[T(X)] = \text{cota de Cramér-Rao} \implies T(X)$  es un UMVUE de  $\tau(\theta)$ .
- Si  $T(X)$  es un estimador insesgado de  $\theta$  y si  $V[T(X)] = \frac{1}{I_F(\theta)} \implies T(X)$  es un UMVUE de  $\theta$ ,  $I_F(\theta)$  para una muestra.
- Definición alternativa para la cota de Cramér-Rao

$$V[T] \geq \frac{\left\{ \frac{\partial}{\partial \theta} E[T(X)] \right\}^2}{I_F(\theta)}$$

con  $I_F(\theta)$  para una muestra.

Si la estimación de máxima verosimilitud de  $\theta$ ,  $\hat{\theta}$  está dada por la solución de la ecuación

$$\frac{\partial}{\partial \theta} \log L(\theta, x_1, \dots, x_n) \equiv \frac{\partial}{\partial \theta} \log \prod_{i=1}^n f(x_i, \theta) = 0$$

y si  $T^* = t^*(X_1, \dots, X_n)$  es un estimador insesgado de  $\tau^*(\theta)$  cuya varianza coincide con la cota inferior de Cramér-Rao, entonces  $t^*(X_1, \dots, X_n) = \tau^*(\hat{\theta})$ .

Bajo estas condiciones un estimador de máxima verosimilitud es UMVUE.

Si  $T^* = t(X_1, \dots, X_n)$  es un estimador insesgado de algún  $\tau^*(\theta)$  cuya varianza coincide con la cota inferior de Cramér-Rao, entonces  $f(\bullet, \theta)$  es miembro de la clase/familia exponencial y viceversa, si  $f(\bullet, \theta)$  es miembro de la familia exponencial, entonces existe un estimador insesgado,  $T^*$  de alguna función  $\tau^*(\theta)$ , cuya varianza coincide con la cota inferior de Cramér-Rao.

## Ejemplo

Sea  $X_1, \dots, X_n$  una muestra aleatoria de una población Bernoulli( $\theta$ ),  $0 < \theta < 1$ . Se pide:

- Encuentre la información de Fisher.
- Sea  $T(X) = \bar{X}$ , muestre que  $T(X)$  es un UMVUE de  $\theta$ .



## Ejemplo

Sea  $X$  una variable aleatoria con distribución  $\text{Poisson}(\theta)$ ,  $\theta > 0$ . Sea la estadística  $T(X) = \begin{cases} 1, & \text{si } x = 0 \\ 0, & \text{e.o.c.} \end{cases} \implies T(X) = 1_{[X=0]}$ . Se pide calcular la cota inferior de Cramér-Rao y la  $V[T(X)]$ . ¿Qué se puede concluir?